

《数字图像处理》期末速通教程

8. 图像复原

8.1 图像退化模型


(看一眼) p193 ~ 196 图像退化模型、图像复原.

[定义 8.1.1]

- (1) 在图像生成、记录、传输过程中, 由成像系统、设备或外在干扰导致图片质量下降, 称为**图像退化**.
- (2) 处理退化图像, 使其恢复原貌的过程称为**图像复原**.
- (3) 图像复原是在给定退化图像 $g(x, y)$ 、了解退化的点扩散函数 $h(x, y)$ 和噪声项 $n(x, y)$ 的情况下, 估计原始图像 $f(x, y)$.

[定义 8.1.2]

- (1) 原图像 $f(x, y)$ 受各种退化因素影响退化为 $g(x, y)$. 退化过程可抽象为一个退化系统 H 和加性噪声 $n(x, y)$ 的影响, 如下图所示.



- (2) **退化模型**: $g(x, y) = H[f(x, y)] + n(x, y)$.

- (3) **一维离散卷积退化模型**: $g_e(x) = \sum_{m=0}^{M-1} f_e(m) \cdot h_e(x - m) \quad (x = 0, 1, \dots, M - 1)$.

用矩阵表示为 $\vec{g} = H\vec{f}$, 其中向量 $\vec{g} = \begin{bmatrix} g_e(0) \\ g_e(1) \\ \vdots \\ g_e(M-1) \end{bmatrix}$, 向量 $\vec{f} = \begin{bmatrix} f_e(0) \\ f_e(1) \\ \vdots \\ f_e(M-1) \end{bmatrix}$, 矩阵

$$H = \begin{bmatrix} h_e(0) & h_e(M-1) & \cdots & h_e(1) \\ h_e(1) & h_e(0) & \cdots & h_e(2) \\ \vdots & \vdots & \ddots & \vdots \\ h_e(M-1) & h_e(M-2) & \cdots & h_e(0) \end{bmatrix}$$

是循环矩阵, 其每一行都是前一行循环右移一位的结果.

(4) **二维离散卷积退化模型**: $g_e(x, y) = \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} f_e(m, n) \cdot h_e(x - m, y - n)$
 $(x = 0, 1, \dots, M - 1; y = 0, 1, \dots, N - 1).$

考虑噪声, 用矩阵表示为 $g = Hf + \vec{n}$, 其中 g 是图像 f 的退化图像, 噪声 $\vec{n} = \begin{bmatrix} n_e(0) \\ n_e(1) \\ \vdots \\ n_e(MN - 1) \end{bmatrix}$, 张量

$H = \begin{bmatrix} H_0 & H_{M-1} & \cdots & H_1 \\ H_1 & H_0 & \cdots & H_2 \\ \vdots & \vdots & \ddots & \vdots \\ H_{M-1} & H_{M-2} & \cdots & H_0 \end{bmatrix}$ 的每个部分 H_j 都是一个循环矩阵, 由延拓函数 $h_e(x, y)$ 的第 j 列构成,

$H_j = \begin{bmatrix} h_e(j, 0) & h_e(j, N-1) & \cdots & h_e(j, 1) \\ h_e(j, 1) & h_e(j, 0) & \cdots & h_e(j, 2) \\ \vdots & \vdots & \ddots & \vdots \\ h_e(j, N-1) & h_e(j, N-2) & \cdots & h_e(j, 0) \end{bmatrix}.$

8.2 图像复原的代数方法

[定义 8.2.1] 图像复原的代数方法是根据二维离散卷积退化模型 $g = Hf + \vec{n}$ 和关于 g 、 H 、 \vec{n} 的某些先验知识, 确定某种最佳准则, 求原图像 f 的最优估计 \hat{f} .

8.2.1 无约束最小二乘复原

[定理 8.2.1.1] [无约束最小二乘复原] 设原图 f 是 $M \times N$ 的矩阵, 且 $M = N$. 已知退化过程 H 和退化图像 g , 若 H 可逆, 则 f 的估计 $\hat{f} = H^{-1}g$.

[证] 由二维离散卷积退化模型 $g = Hf + \vec{n}$, 有 $\vec{n} = g - Hf$.

下求 \hat{f} s.t. $H\hat{f}$ 在最小二乘意义下近似 g , 即 s.t. $\|\vec{n}\| = \|g - H\hat{f}\|^2$ 最小.

定义**最佳准则** $J(\hat{f}) = \|g - H\hat{f}\|^2 = (g - H\hat{f})^T (g - H\hat{f})$, 则 $J(\hat{f})$ 的最小值对应最优解.

下求 $J(\hat{f})$ 的极小值. 令 $\frac{\partial J(\hat{f})}{\partial \hat{f}} = -2H^T (g - H\hat{f}) = 0$,

则 $H^T H\hat{f} = H^T g$, 解得: $\hat{f} = (H^T H)^{-1} H^T g$.

$M = N$ 时, 假设方阵 H 可逆, 则 $\hat{f} = H^{-1}(H^T)^{-1} H^T g = H^{-1}g$.

[注] 因 \hat{f} 的选择不受其它条件约束, 故称**无约束复原**.

8.2.2 约束最小二乘复原

[定义 8.2.2.1]

(1) 在无约束最小二乘复原中附加约束条件, 称为**约束最小二乘复原**.

(2) 约束最小二乘复原一般用 Lagrange 乘数法求解.

设对原图 f 作某一线性运算 Q .

下求在约束条件 $\|\vec{n}\| = \|g - H\hat{f}\|^2$ 下, s.t. $\|Q\hat{f}\|^2$ 最小的 f 的估计 \hat{f} .

设 Lagrange 函数 $J(\hat{f}) = \|Q\hat{f}\|^2 + \lambda \left(\|g - H\hat{f}\|^2 - \|\vec{n}\|^2 \right)$, 其中 λ 为 Lagrange 系数.

$$\text{令 } \frac{\partial J(\hat{f})}{\partial \hat{f}} = 2Q^T Q \hat{f} - 2\lambda H^T (g - H\hat{f}) = 0,$$

$$\text{则 } Q^T Q \hat{f} + \lambda H^T H \hat{f} - \lambda H^T g = 0, \text{ 解得: } \hat{f} = \left(H^T H + \frac{1}{\lambda} Q^T Q \right)^{-1} H^T g.$$

[例 8.2.2.1] 设退化 $\vec{y} = A\vec{x} + \vec{n}$. 求在约束 $\min_{\vec{x}} \|\vec{x}\|_2^2$ 下, s.t. $\|\vec{n}\| = \|\vec{y} - A\vec{x}\|^2$ 最小的向量 \vec{x} 的估计 $\hat{\vec{x}}$, 其中 $\|\vec{x}\|_2 = \left(\sum x_i^2 \right)^{\frac{1}{2}}$.

[解] 设 $\min_{\vec{x}} \|\vec{x}\|_2^2 = C$.

设 Lagrange 函数 $J(\hat{\vec{x}}) = \|\vec{y} - A\vec{x}\|^2 + \lambda \left(\|\vec{x}\|_2^2 - C \right)$, 其中 λ 为 Lagrange 系数.


$$\text{令 } \frac{\partial J(\hat{\vec{x}})}{\partial \hat{\vec{x}}} = -2A^T (\vec{y} - A\vec{x}) + 2\lambda \vec{x} = 0,$$

$$\text{则 } A^T \vec{y} - A^T A \vec{x} = \lambda \vec{x}, \text{ 解得: } \vec{x} = (A^T A + \lambda I)^{-1} A^T \vec{y}.$$

[补充] 向量和矩阵的导数

可参考: <https://www.bilibili.com/video/BV1eZ4y1w7PY/>

[定义] x 和 y 分别取标量和向量时, $\frac{\partial y}{\partial x}$ 的取值如下图所示.



(1) x 是标量, y 是标量时, $\frac{\partial y}{\partial x}$ 是标量.

(2) $\vec{x} = (x_1, \dots, x_n)$ 是向量, y 是标量时, $\frac{\partial y}{\partial \vec{x}} = \left[\frac{\partial y}{\partial x_1}, \dots, \frac{\partial y}{\partial x_n} \right]$ 是行向量.

(3) x 是标量, $\vec{y} = (y_1, \dots, y_m)$ 是向量时, $\frac{\partial \vec{y}}{\partial x} = \begin{bmatrix} \frac{\partial y_1}{\partial x} \\ \vdots \\ \frac{\partial y_m}{\partial x} \end{bmatrix}$ 是列向量.

(4) $\vec{x} = (x_1, \dots, x_n)$ 是向量, $\vec{y} = (y_1, \dots, y_m)$ 是向量时,

$$\frac{\partial \vec{y}}{\partial \vec{x}} = \begin{bmatrix} \frac{\partial y_1}{\partial \vec{x}} \\ \vdots \\ \frac{\partial y_m}{\partial \vec{x}} \end{bmatrix} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \dots & \frac{\partial y_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_m}{\partial x_1} & \dots & \frac{\partial y_m}{\partial x_n} \end{bmatrix} \text{ 是矩阵.}$$

[例 1]

(1) $\vec{x} = (x_1, x_2)$ 时, $\frac{\partial}{\partial \vec{x}}(x_1^2 + 2x_2^2) = \left[\frac{\partial}{\partial x_1} x_1^2, \frac{\partial}{\partial x_2} (2x_2^2) \right] = [2x_1, 4x_2]$.

(2) 设标量 a 非向量 \vec{x} 的函数, 标量 u 是 \vec{x} 的函数, 则:

| y | a | $a \cdot u$ | $\sum x_i$ | $\left \vec{x} \right ^2$ |
|---------------------------------------|--------------------|-----------------------------------------|--------------------|----------------------------|
| $\frac{\partial y}{\partial \vec{x}}$ | 零向量的转置 $\vec{0}^T$ | $a \frac{\partial u}{\partial \vec{x}}$ | 一向量的转置 $\vec{1}^T$ | $2\vec{x}^T$ |

(3) 设向量 $\vec{x} \in \mathbb{R}^n$, 向量 $\vec{y} \in \mathbb{R}^m$, 则 $\frac{\partial \vec{y}}{\partial \vec{x}} \in \mathbb{R}^{m \times n}$.

| y | a | \vec{x} | $A\vec{x}$ | $\vec{x}^T A$ |
|---------------------------------------------|----------------------|----------------------|------------|---------------|
| $\frac{\partial \vec{y}}{\partial \vec{x}}$ | 零矩阵 $0_{m \times n}$ | 一矩阵 $1_{m \times n}$ | A | A^T |

[定理]

(1) 基本运算的导数:

① 设标量 u 和标量 v 都是向量 \vec{x} 的函数, 则:

| y | $u + v$ | $u \cdot v$ |
|---------------------------------------|-----------------------------------------------------------------------------|---------------------------------------------------------------------------------|
| $\frac{\partial y}{\partial \vec{x}}$ | $\frac{\partial u}{\partial \vec{x}} + \frac{\partial v}{\partial \vec{x}}$ | $\frac{\partial u}{\partial \vec{x}} v + \frac{\partial v}{\partial \vec{x}} u$ |

② 设向量 \vec{u} 和向量 \vec{v} 都是向量 \vec{x} 的函数, 则:

| y | $a \cdot \vec{u}$ | $A\vec{u}$ | $\vec{u} + \vec{v}$ | 内积 $\langle \vec{u}, \vec{v} \rangle$ |
|---------------------------------------------|-----------------------------------------------|-----------------------------------------------|-----------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------|
| $\frac{\partial \vec{y}}{\partial \vec{x}}$ | $a \frac{\partial \vec{u}}{\partial \vec{x}}$ | $A \frac{\partial \vec{u}}{\partial \vec{x}}$ | $\frac{\partial \vec{u}}{\partial \vec{x}} + \frac{\partial \vec{v}}{\partial \vec{x}}$ | $\vec{v}^T \cdot \frac{\partial \vec{u}}{\partial \vec{x}} + \vec{u}^T \cdot \frac{\partial \vec{v}}{\partial \vec{x}}$ |

(2) [链式法则]

① 标量: $y = f(u), u = g(x)$, 则 $\frac{\partial y}{\partial x} = \frac{\partial y}{\partial u} \frac{\partial u}{\partial x}$.

② 向量:

| 链式法则 | 维度 |
|-----------------------------------------------------------------------------------------------------------------------------------|--------------------------------|
| $\frac{\partial y}{\partial \vec{x}} = \frac{\partial y}{\partial u} \frac{\partial u}{\partial \vec{x}}$ | $(1, n) = (1) \cdot (1, n)$ |
| $\frac{\partial \vec{y}}{\partial \vec{x}} = \frac{\partial \vec{y}}{\partial \vec{u}} \frac{\partial \vec{u}}{\partial \vec{x}}$ | $(1, n) = (1, k) \cdot (k, n)$ |
| $\frac{\partial \vec{y}}{\partial \vec{x}} = \frac{\partial \vec{y}}{\partial \vec{u}} \frac{\partial \vec{u}}{\partial \vec{x}}$ | $(m, n) = (m, k) \cdot (k, n)$ |

[例 2] 设 $\vec{x} \in \mathbb{R}^n$ 和 $\vec{w} \in \mathbb{R}^n$ 是两无关的向量, 实数 $y \in \mathbb{R}$. 设函数 $z = \left(\langle \vec{x}, \vec{w} \rangle - y \right)^2$, 求 $\frac{\partial z}{\partial \vec{w}}$.

$$\text{[解] 令 } \begin{cases} a = \langle \vec{x}, \vec{w} \rangle \\ b = a - y \\ z = b^2 \end{cases},$$

$$\begin{aligned} \text{则 } \frac{\partial z}{\partial \vec{w}} &= \frac{\partial z}{\partial b} \frac{\partial b}{\partial a} \frac{\partial a}{\partial \vec{w}} = \frac{\partial b^2}{\partial b} \frac{\partial(a - y)}{\partial a} \frac{\partial \langle \vec{x}, \vec{w} \rangle}{\partial \vec{w}} \\ &= (2b) \cdot 1 \cdot \vec{x}^T = 2 \left(\langle \vec{x}, \vec{w} \rangle - y \right) \vec{x}^T. \end{aligned}$$

[例 3] 设 $X \in \mathbb{R}^{m \times n}$ 是与向量 $\vec{w} \in \mathbb{R}^n$ 无关的矩阵, 向量 $\vec{y} \in \mathbb{R}^m$. 设函数 $z = \left\| X\vec{w} - \vec{y} \right\|^2$, 求 $\frac{\partial z}{\partial \vec{w}}$.

$$\text{[解] 令 } \begin{cases} a = X\vec{w} \\ \vec{b} = \vec{a} - \vec{y} \\ z = \left\| \vec{b} \right\|^2 \end{cases},$$

$$\begin{aligned} \text{则 } \frac{\partial z}{\partial \vec{w}} &= \frac{\partial z}{\partial \vec{b}} \frac{\partial \vec{b}}{\partial \vec{a}} \frac{\partial \vec{a}}{\partial \vec{w}} = \frac{\partial \left\| \vec{b} \right\|^2}{\partial \vec{b}} \frac{\partial (\vec{a} - \vec{y})}{\partial \vec{a}} \frac{\partial X\vec{w}}{\partial \vec{w}} \\ &= 2\vec{b}^T \cdot 1_{m \times m} \cdot X = 2 \left(X\vec{w} - \vec{y} \right)^T X. \end{aligned}$$